

Zastosowanie Sieci Konwolucyjnych (CNN) oraz metody *Learning by Confusion* do detekcji przejścia fazowego w dwuwymiarowym modelu Isinga

Radosław Preisler, nr albumu: 286798

6 lipca 2026

1 Wstęp

W ostatnich latach techniki uczenia maszynowego znajdują coraz szersze zastosowanie w fizyce. Tradycyjne podejście do badania przejść fazowych wymaga znajomości parametru porządku (np. magnetyzacji). Ten projekt dotyczy podejścia alternatywnego, w którym sieć neuronowa sama uczy się rozróżniać makroskopowe fazy materii na podstawie mikroskopowych konfiguracji układu. Głównym elementem badań jest metoda *Learning by Confusion*, która pozwala zlokalizować temperaturę krytyczną T_c poprzez analizę momentu największej "dezorientacji" modelu klasyfikacyjnego.

2 Model Isinga

Model Isinga to jeden z fundamentalnych modeli fizyki statystycznej, opisujący zjawisko ferromagnetyzmu. W wariacie dwuwymiarowym (2D) układ składa się z siatki spinów s_i , które mogą przyjmować dwie wartości: $+1$ (spin w górę) lub -1 (spin w dół). Hamiltonian układu, bez zewnętrznego pola magnetycznego, dany jest wzorem:

$$H = -J \sum_{\langle i,j \rangle} s_i s_j \quad (1)$$

gdzie $J > 0$ to stała wymiany, a suma przebiega po parach najbliższych sąsiadów. W niskich temperaturach układ dąży do minimalizacji energii (stan uporządkowany, ferromagnetyczny). W wysokich temperaturach dominują fluktuacje termiczne (stan nieuporządkowany, paramagnetyczny). Dla siatki nieskończonej teoretyczna temperatura przejścia fazowego, obliczona przez Onsagera, wynosi $T_c = \frac{2J}{k_B \ln(1+\sqrt{2})} \approx 2.269 J/k_B$.

3 Generowanie Próbek (Metoda Monte Carlo)

Do wygenerowania zbioru danych (*datasetu*) posłużył algorytm Metropolis. Symulację przeprowadzono na siatkach kwadratowych $L \times L$ (głównie dla $L = 32$) z zastosowaniem periodycznych warunków brzegowych.


W pojedynczym kroku algorytmu losowano spin i obliczano zmianę energii ΔE przy jego ewentualnym odwróceniu. Zmianę akceptowano z prawdopodobieństwem:

$$P = \min \left(1, \exp \left(-\frac{\Delta E}{k_B T} \right) \right) \quad (2)$$

Aby uniknąć korelacji między próbkami oraz zapewnić odpowiednią termalizację, konfiguracje zapisywano dopiero po wykonaniu wielu pełnych sweepów siatki (kroków Monte Carlo). Łącznie

wygenerowano zbiór danych składający się z ok. 200 tys. próbek dla zakresu temperatur $T \in [1.0, 3.5]$, co stanowiło materiał treningowy dla sieci neuronowych.

Różnice w strukturze domen magnetycznych dla poszczególnych faz zostały zaprezentowane na Rysunku 1.



Rysunek 1: Przykładowe konfiguracje spinów (snapshots) wygenerowane z użyciem algorytmu Metropolis. Od lewej: faza uporządkowana (ferromagnetyk), punkt krytyczny (widoczne wielkoskalowe fluktuacje) oraz chaos termiczny (paramagnetyk).

4 Sieci Konwolucyjne (CNN)

Do klasyfikacji wygenerowanych obrazów (macierzy z wartościami $+1$ i -1) zastosowano Sieci Konwolucyjne (CNN). Ich główną zaletą jest zdolność do wykrywania lokalnych korelacji przestrzennych, co idealnie odpowiada fizycznej naturze domen ferromagnetycznych. Co istotne, standardowe operacje splotu zmodyfikowano, dodając parametr (`padding_mode='circular'`). Dzięki temu filtry mogły płynnie przechodzić przez krawędzie siatki, respektując jej periodyczność.

5 Metody Regularyzacji

Ze względu na obecność szumu termicznego w próbkach wysokotemperaturowych, zbyt skomplikowane sieci wykazują tendencję do zapamiętywania losowych konfiguracji (*overfitting*) zamiast nauki praw fizyki. Aby temu zapobiec, wykorzystano trzy techniki regularyzacji:


- **Dropout:** Losowe "wyłączenie" 50% neuronów w fazie treningu, co zmusza sieć do polegania na szerszych wzorcach fizycznych.
- **Batch Normalization:** Normalizacja sygnału pomiędzy warstwami konwolucyjnymi, co stabilizuje wagi.
- **Weight Decay (L2):** Kary nałożone w optymalizatorze za nadmierny wzrost wartości wag, promujące proste reguły decyzyjne.

6 Porównanie Architektur (Test 4 Modeli)


Przed przejściem do wyznaczania temperatury krytycznej, przetestowano cztery różne architektury na zadaniu klasyfikacji (dla z góry założonej temperatury krytycznej), aby ocenić ich skłonność do przeuczania:

1. **Model A (Bazowy):** Płytka sieć konwolucyjna (2 warstwy konwolucyjne: 8 i 16 filtrów). Brak technik regularyzacji, stanowiąca punkt odniesienia.
2. **Model B (Bazowy + regularyzacja):** Architektura identyczna jak w modelu A, jednak zaimplementowana wraz z zestawem metod: L2, Dropout oraz BatchNorm po każdej warstwie splotowej.
3. **Model C (Optymalny):** Sieć głęboka, ale celowo "wąska". Posiada 4 warstwy konwolucyjne (kolejno 8, 16, 16, 32 filtry). Wersja podstawowa dla siatki 32×32 redukuje obraz wyjściowy do wymiaru 2×2 . Wariant dostosowany do siatki 16×16 redukuje sygnał do $(1 \times 1 \times 32)$. Ograniczenie pojemności pamięciowej (mało parametrów w warstwach w pełni połączonych) zmusza sieć do ignorowania szumu termicznego.
4. **Model C* (Przeuczony):** Sieć o podobnej złożoności obliczeniowej co model C, lecz płytsza (3 warstwy splotowe) i znacznie szersza (do 64 filtrów). Generuje ponad 1000 parametrów na wejściu do klasyfikatora, wykazując silną tendencję do zapamiętywania (overfittingu) – mimo włączonej regularyzacji.


Krzywe uczenia badanych modeli zestawiono na poniższych wykresach.




Rysunek 2: Krzywe uczenia dla Modelu A (brak regularyzacji).



Rysunek 3: Krzywe uczenia dla Modelu B.



Rysunek 4: Krzywe uczenia dla optymalnego Modelu C.



Rysunek 5: Krzywe uczenia dla Modelu C* (przeuczonego).

Analizując krzywe uczenia poszczególnych modeli możemy zobaczyć wyraźne różnice w ich zachowaniu, wynikające z ich architektur. Różnica pomiędzy modelem A i B jest bardzo niewielka, ze względu na to, że modele są stosunkowo małe i nie wykazują overfittingu. Wobec tego wprowadzenie regularyzacji prawie nie wpływa na ich zachowanie. Oba modele osiągają dokładność na poziomie $\sim 96\%$.

Model C wykazuje świetną dokładność na zbiorach walidacyjnym i testowym i osiąga dokładność $\sim 99\%$.

Nieodpowiednio skonstruowany Model C* również wykazuje dobrą dokładność na zbiorze testowym, ale krzywa uczenia na zbiorze walidacyjnym zaczyna rosnąć po kilku epokach, co jest oznaką overfittingu. (Dla ilustracji pokazano więcej epok).

7 Schemat *Learning by Confusion* i Skalowanie Rozmiaru


Metoda *Learning by Confusion* (LbC) nie wymaga od sieci wiedzy o teoretycznym położeniu punktu krytycznego. Zamiast tego testuje ona szeroki zakres "zakładanych" temperatur krytycznych T_c^* . Dla każdej wybranej wartości T_c^* algorytm dzieli zbiór danych: próbki wygenerowane w $T < T_c^*$ otrzymują etykietę 0, natomiast próbki z $T > T_c^*$ otrzymują etykietę 1.

Model jest następnie trenowany od zera na sztucznie przypisanych klasach, a jego wydajność jest oceniana.

- Jeśli sztuczne T_c^* leży daleko od prawdziwego T_c , fizyczne stany na obrzeżach są z natury odmienne i łatwe do rozdzielenia (dokładność sieci wynosi niemal 100%).
- Kiedy sztuczne T_c^* trafia na prawdziwe przejście fazowe ($T \approx 2.269$), sieć klasyfikująca gubi się w przyporządkowaniu stanów krytycznych, co owocuje gwałtownym spadkiem dokładności walidacyjnej.

7.1 Porównanie Modeli w metodzie LbC


Na Rysunku 6 zestawiono działanie metody LbC dla obu poprawnie działających architektur – Modelu B oraz zoptymalizowanego Modelu C. Modele wykazują bardzo podobną dokładność i oba produkują charakterystyczny kształt litery "W".



Rysunek 6: Zestawienie działania metody Learning by Confusion dla Modelu B oraz Modelu C ($L = 32$)

7.2 Efekty skończonych rozmiarów (Finite-Size Scaling)

Aby dodatkowo potwierdzić fizyczny sens analizowanych danych, architekturę Modelu C zastosowano także do mniejszego układu – siatki 16×16 spinów. Porównanie głębokości i szerokości dołków klasyfikacyjnych dla rozmiarów $L = 32$ i $L = 16$ ukazano na Rysunku 7.



Rysunek 7: Efekty skończonych rozmiarów w T_c . Wraz ze spadkiem wymiarów siatki (z $L = 32$ na $L = 16$), przejście fazowe ulega poszerzeniu i rozmyciu.

Dla mniejszej siatki ($L = 16$) można zaobserwować występowanie efektów skończonych rozmiarów (*finite-size effects*). Ogólna dokładność klasyfikacji jest zauważalnie niższa w porównaniu do układu $L = 32$. Wynika to z mniejszej objętości układu – silniejsze fluktuacje termiczne na granicach małych domen skuteczniej zaburzają obraz globalnego uporządkowania, utrudniając sieci podjęcie decyzji.

8 Podsumowanie

Przeprowadzony projekt udowadnia, że techniki uczenia maszynowego mogą być z powodzeniem stosowane do analizy złożonych zjawisk fizycznych. Przy użyciu sieci konwolucyjnych (CNN) oraz metody *Learning by Confusion* udało się poprawnie zlokalizować rejon przejścia fazowego w dwuwymiarowym modelu Isinga ($T_c \approx 2.296$), opierając się wyłącznie na surowych konfiguracjach spinów, bez konieczności definiowania parametru porządku.

W trakcie badań wykazano, że kluczowym wyzwaniem w zastosowaniu sztucznej inteligencji do fizyki statystycznej jest odpowiedni dobór pojemności modelu oraz metod regularyzacji. Zbyt szerokie sieci (jak Model C*) wykazywały silną tendencję do przeuczenia się. Dopiero zastosowanie węższej architektury (Model C) oraz technik takich jak Dropout czy L2 pozwoliło modelowi na skupienie się na globalnych strukturach domenowych.

Co istotne, zbieżność wyników LbC dla różnych architektur (Model B i Model C) potwierdza obiektywność zastosowanej metody. Sieci uzyskują maksimum dokładności gdy temperatura krytyczna jest równa wyznaczonej analitycznie. Dodatkowo, analiza mniejszej siatki ($L = 16$)

plytsze minimum "zagubienia" klasyfikatora, co jest bezpośrednim dowodem na rozmycie przejścia fazowego w układach o małej objętości.

Podsumowując, odpowiednio zaprojektowane i zregularyzowane sieci neuronowe stanowią skuteczne i niezależne narzędzie badawcze, zdolne do analizy termodynamiki układów złożonych w sposób czysto oparty na danych (data-driven).